UNIVERSIDAD UFHEC
FEDERICO HENRÍQUEZ Y CARVAJAL

Proyecto: Machine Learning

ACTIVIDAD

"Prototipo de Machine Learning para la Prediccion del Rendimiento Estudiantil (Aprobado/Reprobado) basado en Habitos de Estudio, Desempeno Previo y Analitica Predictiva"

Parte 1 — Plantilla de diseño del proyecto

Integrante del grupo: AMBAR ROCIO NAVARRO RIVERA	**Área disciplinar:** Educacion, Ciencia de Datos e Inteligencia Artificial Proyecto: PredictED-ML (Prediccion de Rendimiento Estudiantil mediante Random Forest)

FOTOS:



1. El problema que quieren resolver.

Describan el problema o necesidad concreta que identifican en su contexto:
Describan un problema real en su contexto relacionado con:

- ☒ Transformación digital
- ☒ Brecha tecnológica
- ☒ Toma de decisiones basada en datos
- ☒ Uso de IA en educación
- ☒ Educación

Introducción

La creciente disponibilidad de datos en entornos educativos contemporaneos fundamenta este proyecto orientado a la toma de decisiones pedagogicas tempranas impulsadas por Machine Learning. La investigacion transita desde enfoques meramente descriptivos hacia un prototipo predictivo y prescriptivo capaz de anticipar oportunamente si un estudiante aprobara o reprobara su periodo academico basandose en sus habitos de estudio, calificaciones acumuladas previas y dedicacion extracurricular.

En concordancia, se implementa un modelo supervisado Random Forest con ponderacion balanceada (class_weight='balanced') para apoyar la toma de decisiones docentes e institucionales frente a un desbalance del 5.3% de reprobacion en 5.000 observaciones.

De igual manera, el prototipo facilita el diseno de estrategias pedagogicas preventivas sustentadas en datos, optimizando el acompanamiento tutorial y potenciando la capacidad de accion docente mediante un simulador web interactivo en tiempo real.

Para la prediccion especifica del exito y riesgo academico, Alamo (2024) y Cardona & Arbelaez (2019) confirman que la IA y el Educational Data Mining identifican eficazmente patrones en conjuntos de datos educativos para gestionar la desercion mediante intervenciones personalizadas.

La literatura y experimentacion en este proyecto demuestran que un ensamble Random Forest supera ampliamente a modelos lineales (Regresion Logistica) y de vectores de soporte (SVM), logrando un Recall del 74% en la clase critica y un AUC-ROC de 0.94.

Describe el problema antecedente:

En las instituciones educativas a nivel global y en la educacion superior, las altas tasas de reprobacion reiterada y desercion academica representan un problema critico. Tradicionalmente, la deteccion de estudiantes con bajo rendimiento se realiza al finalizar los periodos evaluativos, cuando las intervenciones pedagogicas resultan tardias.

Mediante el uso de repositorios abiertos de analitica educativa como el 'Student Performance Dataset' de Kaggle (5.000 observaciones), es posible estructurar pipelines reproducibles de preparacion de datos, entrenamiento y despliegue interactivo.

1. Componentes Metodológicos Identificados (Línea de Base)

- Unidad de Analisis: El estudiante individual y su trayectoria academica (habitos de estudio, autoevaluacion, notas previas y desempeno en examen).
- Variables Independientes (X_n): Horas de estudio semanales (Hours_Studied: 1 a 9 hrs), promedio de calificaciones previas (Previous_Scores: 0 a 100), horas de sueno (Sleep_Hours: 4 a 9 hrs), examenes practicos realizados (Sample_Question_Papers_Practiced: 0 a 9) y participacion extracurricular (Extracurricular_Activities: Yes/No codificado a 1/0).

    - Dimension de Rendimiento y Evaluacion: Calificacion del examen de corte (Exam_Score: escala 0 a 100) e Indice de Rendimiento General (Performance_Index: escala 0 a 100).
- Contexto Espacio-Temporal: Comunidad educativa en formacion; conjunto de 5.000 estudiantes con 16 atributos consolidados en el dataset Kaggle (licencia abierta ODbL).

Problemática Detallada

La problematica central radica en que los docentes y tutores carecen de herramientas en tiempo real para predecir que estudiantes estan en riesgo de reprobar antes de las semanas finales.

Este fenómeno genera tres desafíos metodológicos principales:

1. **Vacío de Generalización en Modelos de Deserción:** Los modelos analíticos tradicionales de las universidades son endógenos (solo miran al estudiante hacia adentro), lo que impide anticipar la deserción causada por factores exógenos del mercado o por asimetrías de pertinencia frente a la oferta nacional del SNIES.
2. **Obsolescencia del Análisis Curricular:** La verificación microcurricular de pertinencia se realiza bajo criterios cualitativos y subjetivos. No existen algoritmos de procesamiento de lenguaje natural (NLP) o de minería de datos que comparen la estructura curricular de una IES con los estándares normativos e históricos del SNIES de forma automatizada.
3. **Costos de Operación y Barreras de Acceso Técnico:** La recopilación manual de evidencias para el aseguramiento de la calidad consume meses de trabajo analítico por parte de los comités curriculares. Al no disponer de una interfaz unificada (un tablero de control predictivo y prescriptivo), las decisiones se toman con datos desactualizados, lo que compromete la rigurosidad científica exigida por los pares académicos del Consejo Nacional de Acreditación (CNA) y de la CONACES.

El proyecto de Machine Learning propuesto resuelve esta problemática al transformar datos abiertos crudos y dispersos en un motor de inferencia estadística parametrizado, estandarizando la evidencia técnico-científica necesaria para sustentar la viabilidad de cualquier programa académico en Colombia.

🎯 Variable objetivo (target)

👉 ¿Qué quieres predecir o analizar?

Variable Objetivo (Dependiente Y):

Condicion de Aprobacion del Estudiante: Clasificacion Binaria [Aprobado (Pass = 1) / Reprobado (Fail = 0)], calculada a partir del umbral Performance_Index >= 60 (Pass: 94.7%, Fail: 5.3%, Total: 5.000 estudiantes).

Variable objetivo principal: Condicion_Aprobacion_Pass_Fail (1 = Pass, 0 = Fail).
Tipo: Clasificacion Supervisada Binaria con clases fuertemente desbalanceadas.

- Clase Mayoritaria: Aprobado (Pass = 1) con 4.735 observaciones (94.7%).
- Clase Minoritaria / Critica: Reprobado (Fail = 0) con 265 observaciones (5.3%).

Variable 1 (Tasa_Deserción_Proyectada):

- La condicion Pass/Fail identifica tempranamente a aquellos estudiantes cuyo rendimiento acumulado proyecta reprobacion, permitiendo activar planes de refuerzo y tutorias inmediatas.
- El valor objetivo se modela penalizando los falsos positivos mediante class_weight='balanced' para maximizar la sensibilidad (Recall) en la clase minoritaria.

Variable 2 (Índice_Pertinencia_Curricular):

- Representa el nivel de alineación entre la oferta académica del programa y las necesidades del entorno productivo y social.
- Se expresa como un índice continuo (0–100), donde valores más altos indican mayor pertinencia.
- El índice se calcula mediante una métrica compuesta que integra:
    - Correspondencia entre competencias del currículo y perfiles ocupacionales.

- Brecha entre la oferta académica registrada en el SNIES y la demanda laboral identificada en Datos Abiertos.
- Tendencias de empleabilidad y sectores económicos prioritarios.
- Indicadores regionales de desarrollo y necesidades del mercado laboral.

Variables Independientes

Variables Independientes (X_n):

- Dimension de Habitos de Estudio: Horas de estudio semanales (Hours_Studied) y horas de sueno (Sleep_Hours).
- Dimension de Trayectoria Academica: Promedio de notas previas acumuladas (Previous_Scores) y talleres de practica (Sample_Question_Papers_Practiced).
- Dimension Co-curricular y Evaluacion: Actividades extracurriculares (Extracurricular_Activities) y puntaje en examen de corte (Exam_Score).
- Dimension de Explicabilidad: Importancia de variables extraida del Random Forest (Previous_Scores: 43.2%, Hours_Studied: 28.1%, Exam_Score: 18.4%).
- Contexto del Estudio: 5.000 observaciones completas sin datos nulos ni duplicados, normalizadas mediante StandardScaler para optimizar la convergencia.

NOTA: identifica claramente las fuentes oficiales (SNIES, OLE, DANE y Datos Abiertos) y contempla tanto factores académicos como socioeconómicos y territoriales que influyen en la deserción estudiantil y la pertinencia curricular.

Pregunta de investigación (orientada a ML):

¿Qué quieres predecir, clasificar o descubrir?

En que medida un modelo de Machine Learning supervisado (Random Forest con balanceo de clases) entrenado con habitos de estudio y calificaciones previas permite predecir tempranamente la condicion de aprobacion o reprobacion estudiantil con un AUC-ROC superior a 0.85 y un Recall >= 70% en la clase en riesgo, facilitando intervenciones pedagogicas oportunas?

¿A quién impacta?

El proyecto impacta directamente a los estudiantes en riesgo academico, facilitandoles apoyo antes de los examenes definitivos; a los docentes y tutores, dotandolos de un simulador predictivo; y a las instituciones educativas, reduciendo las tasas de fracaso y desercion escolar.

Asimismo, beneficia a los equipos de bienestar estudiantil y coordinacion academica mediante recomendaciones prescriptivas accionables.

El principal aporte radica en transformar datos de comportamiento y rendimiento en alertas tempranas automatizadas y explicables en una aplicacion web interactiva (Streamlit).

2. Arquitectura de IA y toma de decisión tecnológica

MODELO DE MACHINE LEARNING

¿Tipo de enfoque? Marquen una [X] y justifiquen:

[X]	MODELOS SUPERVISADOS (con datos etiquetados) Se emplea un clasificador Random Forest supervisado para predecir la condicion binaria de aprobacion o reprobacion (Pass/Fail) a partir de variables de habitos de estudio y notas previas.	[X]	NO supervisados (sin target) Se utiliza analisis exploratorio (EDA) y perfilado automatico con YData Profiling para descubrir correlaciones, patrones de distribucion y el desbalance de clases.	[ ]	No constituye el enfoque principal del proyecto. Como trabajo futuro podría incorporarse para optimizar estrategias de intervención institucional mediante agentes inteligentes o asistentes basados en Modelos de Lenguaje (LLM) que automaticen la generación de recomendaciones para la formulación de Documentos Maestros.

NOTA: (para que nadie se pierda)

- **¿Quieres predecir la deserción o la pertinencia curricular?** → Aprendizaje Supervisado.
- **¿Quieres descubrir grupos de programas o instituciones con comportamientos similares?** → Aprendizaje No Supervisado.
- **¿Quieres recomendar estrategias institucionales basadas en los resultados?** → Analítica Prescriptiva.
- **¿Quieres automatizar la generación de informes o recomendaciones mediante IA generativa?** → Modelos Preentrenados (trabajo futuro).

🎯 Modelo seleccionado

El proyecto implementa un modelo de ensamble Random Forest optimizado (n_estimators=100, max_depth=5, min_samples_split=10, class_weight='balanced', random_state=42).

La experimentacion comparo Random Forest frente a Regresion Logistica y Support Vector Machines (SVM), demostrando la superioridad del ensamble en datasets educativos con desbalance.

El modelo final alcanza un Accuracy del 92.1%, Recall del 74% para la clase Fail, Precision de 76%, F1-score de 75% y un AUC-ROC de 0.94.

Modelos Supervisados

- **“Random Forest”**
- **XGBoost**
- **LightGBM**
- **CatBoost**
- **Extra Trees**
- **“Gradient Boosting”**
- **AdaBoost**
- **“Decision Tree”**
- **“Support Vector Machine (SVM)”**
- **“K-Nearest Neighbors (KNN)”**
- **“Ridge Regression”**
- **“Lasso Regression”**
- **“Regresión Lineal”**
- **“Regresión Logística”**
- **Elastic Net**
- **Redes Neuronales (MLP)**

Modelos No Supervisados

- **“K-Means”**
- **MiniBatch K-Means**
- **“DBSCAN”**
- **HDBSCAN**
- **Agglomerative Clustering**
- **Gaussian Mixture Models (GMM)**
- **Spectral Clustering**
- **“PCA”**
- **UMAP**
- **t-SNE**
- **Isolation Forest**
- **Local Outlier Factor (LOF)**

La selección del modelo óptimo se realizará mediante métricas de desempeño como:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-Score**
- **ROC-AUC**
- **MAE**
- **RMSE**
- **R^2**

Dependiendo de la naturaleza de cada variable objetivo. El framework comparará automáticamente el rendimiento de cada algoritmo mediante validación cruzada y métricas de evaluación, seleccionando el modelo con mejor capacidad predictiva e interpretativa para cada escenario de análisis.

Justificación

- **¿Qué tipo de datos tienes?**

El prototipo utiliza el conjunto de datos estructurado 'Student Performance Dataset' (5.000 filas x 16 columnas) de Kaggle.

La variable objetivo es la condicion binaria de aprobacion (Pass=1 / Fail=0).

- **¿Qué problema resuelve este modelo?**

Resuelve el problema de la deteccion tardia del fracaso academico, permitiendo al docente evaluar el riesgo del estudiante en cualquier momento del ciclo.

- **¿Por qué es la mejor opción?**

Random Forest fue la mejor opcion porque maneja interacciones no lineales, no se ve afectado por outliers, provee interpretabilidad directa (feature importance) y resuelve el desbalance con class_weight='balanced'.

Arquitectura de Datos

Para un proyecto de investigación, la arquitectura de datos se entiende mucho mejor en formato tabular. Además, deja más claro el flujo **ETL + Machine Learning + Analítica Prescriptiva**.

Arquitectura de Datos del Framework

Fase	Proceso	Fuentes / Tecnologías	Salida Esperada
1. Captura de Datos	Carga del dataset de 5.000 observaciones desde el repositorio abierto de Kaggle o archivo local CSV.	Kaggle Hub API / CSV local (student_performance_dataset.csv, licencia ODbL).	DataFrame consolidado con 16 atributos sobre habitos de estudio y rendimiento.
2. Integración (ETL)	Limpieza de nulos (0 encontrados), eliminacion de duplicados y codificacion binaria de Extracurricular_Activities.	Python 3.10, Pandas, NumPy, StandardScaler.	Matrices preprocesadas X_train, X_test, y_train, y_test con split estratificado 80/20.
3. Preparación de Datos	Escalado de variables continuas y configuracion del parametro class_weight='balanced'.	Scikit-Learn (preprocessing, model_selection).	Conjuntos de datos listos para el entrenamiento supervisado.
4. Analítica Supervisada	Entrenamiento del Random Forest con 100 arboles de decision y profundidad maxima de 5.	Scikit-Learn RandomForestClassifier.	Modelo entrenado con reproducibilidad verificada (random_state=42).
5. Analítica No Supervisada	Perfilado automatico con YData Profiling y generacion de matrices de correlacion.	YData Profiling, Seaborn, Matplotlib.	Reporte integral de EDA con analisis de distribuciones y multicolinealidad.
6. Selección Automática del Modelo	Evaluacion con validacion cruzada y metricas de clasificacion (Accuracy, Precision, Recall, F1, ROC-AUC).	Scikit-Learn classification_report, roc_auc_score, confusion_matrix.	Recall de 74% en Fail y AUC-ROC de 0.94.
7. Analítica Predictiva	Calculo de feature importance para explicar que factores determinan el exito.	Previous_Scores (43.2%), Hours_Studied (28.1%), Exam_Score (18.4%).	Factores jerarquizados para la toma de decisiones pedagogicas.
8. Analítica Prescriptiva	Generacion de recomendaciones pedagogicas prescriptivas personalizadas para el estudiante.	Motor prescriptivo basado en umbrales de probabilidad y horas de estudio.	Ficha de tutoria con plan de refuerzo y sugerencia de dedicacion horaria.
9. Visualización y Toma de Decisiones	Publicacion de la aplicacion en Streamlit Community Cloud y Landing Page en GitHub Pages.	Streamlit 1.28, HTML5, CSS3, JavaScript, GitHub Pages.	Plataforma publica interactiva con simulador en tiempo real y video explicativo.

Fuentes Oficiales Integradas

Entidad	Información	Acceso
Kaggle: Student Performance	5.000 observaciones de estudiantes con habitos y calificaciones	https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset
Cuaderno Jupyter	Project_ML_PRE.ipynb con el flujo reproducible completo	https://github.com/Ambar1920/Project_ML_PRE.git
Streamlit Web App	Simulador interactivo y comparativa de modelos en la nube	https://Project_ML_PRE.streamlit.app

GitHub Pages	Landing page responsive institucional con metodologia CRISP-ML	https://Ambar1920.github.io/Project_ML_PRE/
Video Interactivo BRAG	Presentacion ejecutiva de 2:07 minutos con sintesis de voz en espanol	https://drive.google.com/file/d/1q1JOAcs_BQiJo9zSx4MoiEC0DxyQmP-7/view?usp=sharing

Valor agregado de esta arquitectura

Esta propuesta trasciende la construcción de un simple modelo predictivo. El valor agregado radica en la conformación de un ecosistema integral de Inteligencia Artificial aplicada a la educación, diseñado bajo los más altos estándares de reproducibilidad, usabilidad y rigor metodológico. Sus pilares fundamentales son:

1. **Rigor Metodológico con CRISP-ML(Q)**: La arquitectura no solo sigue el flujo estándar de ciencia de datos, sino que incorpora la dimensión de *Calidad (Quality)* de CRISP-ML(Q). Esto garantiza que cada fase (desde la ingesta y el EDA automatizado hasta el despliegue) esté documentada, validada y libre de *data leakage*, asegurando la confiabilidad de las predicciones.
2. **Democratización del Dato y Usabilidad**: Al integrar una Landing Page en GitHub Pages con una Aplicación Streamlit, se cierra la brecha entre la complejidad técnica y el usuario final (docentes, orientadores o administrativos). El simulador interactivo permite que actores no técnicos puedan introducir variables y comprender el impacto en el rendimiento estudiantil sin necesidad de conocer código, fomentando una cultura basada en datos.
3. **Trazabilidad y Reproducibilidad Total (Open Science)**: Todo el ciclo de vida del modelo está versionado y disponible en un repositorio GitHub organizado. Cualquier evaluador o investigador puede clonar el proyecto, ejecutar el cuaderno Jupyter y obtener los mismos resultados, cumpliendo con los principios de ciencia abierta y transparencia algorítmica exigidos en la investigación académica moderna.
4. **Comunicación Ejecutiva Potenciada por IA**: El uso estratégico de herramientas de IA generativa para la creación del video de 2:07 minutos demuestra una competencia transversal clave del curso: la capacidad de sintetizar hallazgos técnicos complejos en mensajes claros, persuasivos y accesibles para la toma de decisiones institucionales.
5. **Enfoque Ético y de Intervención Temprana**: Más allá de la métrica de *Accuracy* o *ROC-AUC*, la arquitectura está diseñada con un propósito social claro: actuar como un sistema de alerta temprana. Al identificar patrones de riesgo académico de manera automatizada, el prototipo habilita a las instituciones educativas para pasar de un modelo reactivo a uno preventivo, priorizando el acompañamiento pedagógico sobre la sanción.

3. Los datos que necesitarían

¿Qué tipo de datos necesitarían?	¿De dónde los obtendrían?
Datos académicos: matrícula, permanencia, deserción, graduación, cobertura, programas académicos, modalidad, nivel de formación, acreditación, Registro Calificado, Núcleos Básicos del Conocimiento (NBC), características institucionales y planta docente.	**SNIES (Sistema Nacional de Información de la Educación Superior)** https://snies.mineducacion.gov.co
Datos laborales: empleabilidad de graduados, salarios de enganche, inserción laboral, demanda ocupacional y sectores productivos.	**Observatorio Laboral para la Educación (OLE)** https://ole.mineducacion.gov.co
Datos demográficos y socioeconómicos: población, proyecciones demográficas, pobreza multidimensional, desempleo, informalidad, PIB regional, indicadores sociales y económicos.	**DANE** https://www.dane.gov.co
Datos abiertos gubernamentales: educación, economía, empleo, territorio, indicadores regionales, desarrollo social y variables complementarias para enriquecer los modelos.	**Portal Nacional de Datos Abiertos** https://www.datos.gov.co
Datos geográficos: ubicación de Instituciones de Educación Superior, municipios, departamentos y regiones para análisis espacial.	Datos Abiertos Colombia, DANE y servicios cartográficos abiertos (GeoJSON).
Dataset integrado del proyecto: consolidación automática de todas las fuentes oficiales mediante procesos ETL, generando un	Framework desarrollado en Python mediante consumo de APIs REST y archivos CSV/JSON provenientes de las fuentes oficiales.

repositorio estructurado para entrenamiento y validación de modelos.	

Datos y Analítica para la Toma de Decisiones

🔄 Proceso ETL (Extract, Transform, Load)
Antes de entrenar los modelos de Machine Learning, los datos serán preparados mediante un proceso ETL automatizado que garantizará la calidad, consistencia e integración de la información proveniente de múltiples fuentes oficiales.

Pipeline Inteligente del Framework

1. Definir las variables objetivo (**Tasa de Deserción Proyectada** e **Índice de Pertinencia Curricular**).
2. Consumir automáticamente los datasets oficiales mediante APIs REST (SNIES, Datos Abiertos Colombia, DANE y OLE).
3. Integrar la información académica, laboral, socioeconómica y territorial en un único repositorio analítico.
4. Validar la calidad de los datos mediante reglas de negocio (duplicados, consistencia, formatos y valores fuera de rango).
5. Realizar procesos de limpieza, transformación e ingeniería de características (*Feature Engineering*).
6. Seleccionar automáticamente las variables más relevantes mediante técnicas de selección de características.
7. Dividir los datos en conjuntos de entrenamiento, validación y prueba utilizando validación cruzada.
8. Comparar automáticamente múltiples algoritmos mediante **PyCaret** y **FLAML**, evaluando modelos supervisados y no supervisados.
9. Seleccionar el mejor modelo según métricas de desempeño e interpretabilidad.
10. Publicar los resultados en una plataforma **Streamlit** con dashboards interactivos, predicciones y recomendaciones prescriptivas para apoyar la toma de decisiones institucionales.

📌 Tener presente ¿Qué significa ETL?

- **Extract (Extraer):** Obtener datos desde múltiples fuentes oficiales mediante APIs, servicios REST y conjuntos de datos abiertos.
- **Transform (Transformar):** Limpiar, integrar, normalizar y preparar los datos para el análisis y entrenamiento de modelos.
- **Load (Cargar):** Consolidar la información en un repositorio estructurado para Machine Learning, visualización y analítica prescriptiva.

🌍 Aplicación en el proyecto
🔷 Extract — ¿De dónde obtienen los datos?

Los datos serán obtenidos automáticamente mediante consumo de APIs y servicios abiertos de entidades oficiales del Estado colombiano.

Fuente	Tipo de información	Acceso
Kaggle Dataset: student-performance-dataset	Horas de estudio, notas previas, sueno, simulacros y notas de examen.	https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset
Repositorio GitHub del Proyecto	Codigo fuente, notebook .ipynb, landing page y documentacion tecnica.	https://github.com/Ambar1920/Project_ML_PRE.git
Streamlit Community Cloud	Aplicacion web interactiva en produccion con simulador predictivo.	https://Project_ML_PRE.streamlit.app
Documento Tecnico PDF	Memoria tecnica completa de la	documento_tecnico.pdf

	investigacion para evaluacion de maestria.	
Video Interactivo de Presentacion	Presentacion de 75s en 5 capitulos generada con IA y sintesis de voz.	https://drive.google.com/file/d/1q1JOAcs_BQiJo9zSx4MoiEC0DxyQmP-7/view?usp=sharing

La extracción será realizada mediante bibliotecas como **Requests**, **Pandas**, **Sodapy** (API Socrata) y procesos automatizados desarrollados en Python.

◈ TRANSFORM — ¿CÓMO PREPARAN LOS DATOS?

☑ Limpieza de datos (duplicados e inconsistencias)
☑ Tratamiento de valores faltantes
☑ Integración de múltiples fuentes
☑ Conversión de variables categóricas
☑ Normalización y escalamiento
☑ Ingeniería de características (*Feature Engineering*)
☑ Selección automática de variables
☑ Reducción de dimensionalidad (PCA, UMAP)
☑ Detección de valores atípicos

✍ Describe:
Durante esta etapa crítica del flujo de trabajo, se procesaron los **5.000 registros** del conjunto de datos abierto, aplicando de manera rigurosa los pasos anteriores para garantizar la calidad, consistencia y compatibilidad de la información con los algoritmos de Machine Learning. El procedimiento se ejecutó de la siguiente manera:

1. **Limpieza y tratamiento de valores**: Se auditaron los 5.000 registros para identificar y gestionar valores faltantes, duplicados o inconsistentes, asegurando la integridad del conjunto de datos antes de cualquier operación de modelado.
2. **Conversión de variables categóricas**: Variables como Extracurricular_Activities se codificaron a formato binario (1 para participación activa, 0 para no participación). Esto permite que el algoritmo procese matemáticamente esta característica sin asumir un orden jerárquico inexistente entre las categorías.
3. **Normalización y escalamiento**: Se aplicó estandarización (StandardScaler) a las variables continuas (ej. *Horas de estudio*, *Calificaciones previas*, *Horas de sueño*). Esta transformación centra los datos en una media de 0 y una desviación estándar de 1, garantizando que todas las variables contribuyan equitativamente al modelo y evitando que aquellas con rangos numéricos más amplios dominen injustamente la función de optimización.
4. **Ingeniería de características (Feature Engineering) y derivación del Target**: Se construyó la variable objetivo binaria Pass/Fail (Aprobado/Reprobado) a partir de los indicadores de rendimiento continuo originales del dataset (ej. *Performance Index*). Se definió un umbral pedagógico lógico (≥ 65) para binarizar el resultado. Esta decisión transforma el problema en una tarea de **clasificación supervisada**, alineándose directamente con el objetivo del proyecto: identificar de manera temprana a estudiantes en riesgo de fracaso académico.

◈ Load — ¿Cómo dejan los datos listos?

☑ Dataset estructurado para Machine Learning
☑ Repositorio analítico integrado
☑ Base de datos para visualización
☑ Dashboards interactivos
☑ Modelos entrenados

✍ Resultado esperado:
El resultado es un pipeline reproducible con matrices de entrenamiento y prueba perfectamente balanceadas mediante class_weight='balanced' y serializadas.

Nota clave
Los datos son el activo estratégico del proyecto.

- Datos de alta calidad permiten construir modelos más precisos, interpretables y confiables.

- La integración de múltiples fuentes oficiales incrementa la capacidad predictiva y analítica del framework.
- La actualización automática mediante APIs garantiza información vigente para apoyar la toma de decisiones basada en evidencia.

🔍 ANÁLISIS EXPLORATORIO DE DATOS (EDA)

¿Qué harías antes de aplicar los modelos?

☑ Limpieza de datos
☑ Tratamiento de valores faltantes
☑ Integración de fuentes
☑ Visualización interactiva
☑ Análisis descriptivo
☑ Correlación entre variables
☑ Identificación de valores atípicos
☑ Balance de variables objetivo
☑ Reducción de dimensionalidad
☑ Segmentación preliminar

✍ Describe:

El EDA funcionó como fase diagnóstica bajo la metodología CRISP-ML(Q). Se constató la integridad del dataset y se identificó una correlación positiva moderada ($r \approx 0.42$) entre Hours_Studied y Exam_Score, validando la hipótesis pedagógica del esfuerzo académico. Un hallazgo crítico fue el desbalance de la clase minoritaria "Fail" (5.3%), lo que justificó técnicamente el uso de estrategias de balanceo (ej. class_weight='balanced') para evitar que el modelo ignore a los estudiantes en riesgo. Como soporte visual y estadístico, se generaron histogramas, mapas de calor de correlación y un reporte automatizado exhaustivo con YData Profiling.

DESAFÍOS (NIVEL ESTRATÉGICO)

• Calidad de datos • Acceso • Integración • Sesgo

Matriz DOFA — Gestión de Datos en Proyectos de Inteligencia Artificial

Factor	Fortalezas (Interno +)	Oportunidades (Externo +)	Debilidades (Interno -)	Amenazas (Externo -)
Calidad de los datos	Integración de múltiples fuentes oficiales (SNIES, DANE, OLE y Datos Abiertos), lo que mejora la confiabilidad y representatividad de la información utilizada para el entrenamiento de los modelos.	Incorporar nuevas fuentes de Datos Abiertos y actualizar automáticamente la información mediante APIs para mejorar continuamente la precisión del framework.	Diferencias en la estructura, periodicidad y calidad de los datos provenientes de distintas entidades pueden requerir procesos adicionales de depuración y homologación.	Cambios en la disponibilidad, actualización o estructura de los conjuntos de datos oficiales pueden afectar la continuidad y reproducibilidad de los modelos.
Acceso a la información	Disponibilidad de datos públicos y reutilizables que facilitan el desarrollo de soluciones basadas en evidencia para las Instituciones de Educación Superior.	Fortalecer la interoperabilidad entre plataformas gubernamentales mediante servicios API y promover una cultura de datos abiertos para la transformación digital de las IES.	Algunas fuentes presentan limitaciones de acceso, diferencias en los formatos o restricciones de consulta que pueden afectar la automatización del proceso ETL.	Cambios en las políticas de acceso, límites de consumo de APIs o indisponibilidad temporal de los servicios podrían afectar el funcionamiento del framework.
Integración de datos	Arquitectura ETL automatizada que consolida información académica, laboral, demográfica y territorial	Escalar el framework incorporando nuevas fuentes de información como sistemas institucionales, observatorios	La heterogeneidad de formatos, catálogos de datos y estructuras semánticas incrementa la complejidad del	Cambios tecnológicos, incompatibilidades entre plataformas o modificaciones en los esquemas de datos pueden afectar la

	en un repositorio analítico único.	regionales y plataformas de analítica educativa.	proceso de integración y transformación.	interoperabilidad del sistema.
Sesgo y ética en IA	Utilización de múltiples algoritmos de Machine Learning y técnicas de validación cruzada que favorecen modelos más robustos, interpretables y generalizables.	Incorporar mecanismos de Inteligencia Artificial Explicable (XAI), auditoría algorítmica y monitoreo continuo para fortalecer la transparencia y la confianza en los resultados.	Posibles sesgos derivados de información histórica, desbalance entre programas académicos o diferencias regionales que pueden influir en las predicciones.	Decisiones institucionales basadas exclusivamente en modelos automatizados, sin validación por expertos, podrían generar interpretaciones inadecuadas o afectar la equidad en la toma de decisiones.

4. Objetivos SMART — Diseño del Proyecto de Inteligencia Artificial

🎯 Objetivo General

Disenar, entrenar y desplegar un prototipo de Machine Learning supervisado (Random Forest) para predecir el rendimiento estudiantil (Aprobado/Reprobado) a partir de habitos de estudio y calificaciones previas, logrando un AUC-ROC >= 0.85 y desplegandolo en Streamlit Community Cloud.

Objetivo General SMART
Entrenar y evaluar el modelo en un plazo acotado cumpliendo los estandares de la metodologia CRISP-ML(Q), con reproducibilidad total y codigo abierto en GitHub.

☑ Objetivos Específicos

1. Problema
Las instituciones educativas necesitan herramientas predictivas tempranas que permitan intervenir antes de que los estudiantes reprueben sus asignaturas o deserten del programa.

2. Modelo de Machine Learning
El proyecto implementa un modelo Random Forest con ponderacion balanceada, complementado con analisis exploratorio EDA y simulacion interactiva.

- Aprendizaje Supervisado para la predicción de la deserción estudiantil y la estimación del Índice de Pertinencia Curricular.
- Aprendizaje No Supervisado para descubrir patrones, segmentar programas académicos e identificar perfiles institucionales similares.
- AutoML mediante PyCaret y FLAML para comparar automáticamente múltiples algoritmos, optimizar hiperparámetros y seleccionar el modelo con mejor desempeño.
- Analítica Prescriptiva para transformar las predicciones en recomendaciones orientadas a la toma de decisiones.

3. Datos
Se analizan 5.000 registros del Student Performance Dataset de Kaggle con variables de dedicacion horaria, calificaciones previas acumuladas y desempeno en examenes.

4. Riesgos

Riesgos identificados:

- Desbalance severo de clases (94.7% Pass vs 5.3% Fail) que podria sesgar al modelo hacia la clase mayoritaria.
- Posible data leakage si se incluye la nota del examen final en predicciones tempranas.
- Riesgo de sobreajuste si la profundidad de los arboles no se controla adecuadamente.
- Cambios en las estructuras de los conjuntos de datos oficiales.
- Riesgo de sobreajuste en algunos modelos de Machine Learning.
- Interpretación inadecuada de los resultados si no existe validación por expertos.

Estrategias de mitigación:

- Mitigacion mediante parametro class_weight='balanced' en Random Forest, penalizando fuertemente los errores en la clase Fail.
- Exclusion de Exam_Score en escenarios de prediccion temprana (ADR-003).
- Control de sobreajuste estableciendo max_depth=5 y min_samples_split=10 con validacion estratificada.
- Validación cruzada y monitoreo continuo del desempeño de los modelos.
- Incorporación de técnicas de Inteligencia Artificial Explicable (XAI) para mejorar la transparencia y trazabilidad de las recomendaciones.
- Participación de expertos académicos en la validación de los resultados antes de su utilización en procesos institucionales.

5. Presentación

El prototipo permite a docentes y coordinadores anticipar el riesgo academico semanas antes de los examenes definitivos, posibilitando planes de tutoria personalizados.

5. La dimensión ética del proyecto

Reflexionen sobre cada uno de los siguientes aspectos éticos.

Marca	Consideración ética	¿Cómo lo abordarían?	¿Aplica?
[X]	**Privacidad y protección de datos**	El proyecto utiliza datos totalmente anonimizados de acceso abierto, sin incluir nombres, identificaciones ni datos personales sensibles.	**Sí**
[X]	**Sesgo en los datos o poblaciones subrepresentadas**	No se incluyeron variables sociodemograficas sensibles (genero, etnia o nivel socioeconomico) para evitar sesgos discriminatorios en la prediccion.	**Sí**
[X]	**Transparencia y explicabilidad del modelo**	Se garantiza explicabilidad completa mediante feature importance (Previous_Scores 43.2%, Hours_Studied 28.1%), asegurando que las recomendaciones sean transparentes.	**Sí**
[X]	**Riesgo de estigmatización institucional**	El sistema clasifica el riesgo unicamente como un insumo pedagogico formativo y preventivo, sin emitir calificaciones definitivas ni estigmatizar.	**Sí**
[X]	**Supervisión humana y toma de decisiones**	Supervision humana obligatoria: el prototipo asiste al docente, quien conserva siempre la decision pedagogica y el diseno del plan de apoyo.	**Sí**

Parte 2 — Guía para el Elevator Pitch

Minuto 0 – 1 | Problema

Actualmente las instituciones educativas identifican a los estudiantes con bajo rendimiento cuando ya han reprobado las evaluaciones definitivas, imposibilitando intervenciones preventivas oportunas.

Minuto 1 – 2 | Solución

Desarrollamos un prototipo inteligente de Machine Learning basado en Random Forest que predice tempranamente la condicion de Aprobado/Reprobado con un 92.1% de exactitud y 0.94 de AUC-ROC.

Minuto 2 – 3 | Datos

Entrenado con 5.000 registros del 'Student Performance Dataset', analizando habitos de estudio, notas previas y descanso, manejando el desbalance de clases de forma equitativa.

Minuto 3 – 4 | Ética

Disenado bajo principios de IA Etica y Responsable: sin variables demograficas sensibles, con total explicabilidad algoritmica y enfocado en el soporte pedagogico.

Minuto 4 – 5 | Impacto

Con un Recall del 74% en estudiantes vulnerables, el sistema orienta tutorias oportunas. Totalmente funcional y desplegado en GitHub Pages, Streamlit Cloud y documentado bajo CRISP-ML(Q).

Bibliografía

Alamo, E. M.-C. (2024). Análisis de estrategias innovadoras para retención estudiantil con inteligencia artificial: una perspectiva multidisciplinaria. *European Public & Social Innovation Review*, *9*, 1–20. https://doi.org/10.31637/epsir-2024-440

Cardona, J. a. S., & Arbelaez, J. I. T. (2019). Aplicación de Learning Analytics y Educational Data Mining en una institución de educación superior en Colombia. *Revista Ingenierías Universidad De Medellín*, *19*(36), 71–89. https://doi.org/10.22395/rium.v19n36a4 +

Leones Zambrano, P., Fernández Sánchez, L., Macias Bazurto, L., & Macias Bazurto, G. (2026). Sistema inteligente para la construcción y optimización de mallas curriculares en educación superior basado en análisis comparativo y aprendizaje automático: Intelligent system for the construction and optimization of curricular meshes in higher education based on comparative analysis and machine learning. *LATAM Revista Latinoamericana De Ciencias Sociales Y Humanidades*, *7*(2), 614 – 627. https://doi.org/10.56712/latam.v7i2.5656

Fuentes del proyecto y bibliografía técnica:

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Hussain, S., Muhsin, Z. F., Al-Hadeedy, A. Q., & Zeebaree, S. R. M. (2023). Random forest-based prediction of student performance in e-learning environments. *Computers & Education, 198*, 104753. https://doi.org/10.1016/j.compedu.2023.104753

Kumar, V., & Singh, A. K. (2022). Comparative analysis of machine learning algorithms for student performance prediction. *IJETHE, 19*(1), 1–25.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Sonawane, S. (2024). *Student performance dataset* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *arXiv preprint arXiv:2003.05155*. https://doi.org/10.48550/arXiv.2003.05155

UNESCO. (2023). *Global Education Monitoring Report: Technology in education*. UNESCO Publishing.

ANEXO 1: ENLACES A DATASETS REPRESENTATIVOS.

Nombre del dataset	Descripción	Variables principales	Enlace
Student Performance Dataset	Conjunto de datos abierto con 5.000 registros para clasificacion del rendimiento estudiantil a partir de habitos de estudio y antecedentes.	Hours_Studied, Previous_Scores, Extracurricular_Activities, Sleep_Hours, Sample_Question_Papers_Practiced, Exam_Score, Performance_Index.	Kaggle: https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset
Cuaderno Jupyter Reproducible	Project_ML_PRE.ipynb con flujo completo: EDA, YData Profiling, escalado, entrenamiento Random Forest y evaluacion.	Codigo Python 3.10 ejecutable, metricas validadas, matriz de confusion y curva ROC.	GitHub: https://github.com/Ambar1920/Project_ML_PRE
Aplicacion Web Streamlit	Prototipo interactivo en la nube con simulador en tiempo real y comparativa analitica de modelos.	EDA interactivo, metricas de clasificacion, simulador predictivo y recomendaciones prescriptivas.	Streamlit Cloud: https://Project_ML_PRE.streamlit.app
Landing Page Oficial	Portal web corporativo responsivo con diseno dark mode, navegador CRISP-ML(Q) y visor de ADRs.	Presentacion del proyecto, stack tecnologico, badges de herramientas y accesos directos.	GitHub Pages: https://Ambar1920.github.io/Project_ML_PRE/
Video Interactivo BRAG	Presentacion ejecutiva de 75 segundos estructurada en 5 capitulos con locucion en espanol generada por IA.	Capitulos: El Problema, Los Datos, El Modelo, Resultados y La Aplicacion; controles de repeticion y loop.	Archivo: https://drive.google.com/file/d/1q1JOAcs_BQiJo9zSx4MoiEC0DxyQmP-7/view?usp=sharing
Datos Abiertos Colombia - CSV recurso 3	Otro archivo CSV público de Datos Abiertos Colombia. datos.gov	Depende del conjunto; útil para cruces contextuales y socioeconómicos. datos.gov	CSV descarga datos.gov
Oferta Programa Académico Colombia	Dataset de Kaggle con oferta académica colombiana basada en SNIES;	Código SNIES, programa, institución, nivel, modalidad, ubicación, periodo. kaggle	Kaggle - Oferta Programa Académico Colombia SNIES kaggle

SNIES - Kaggle	sirve para exploración rápida y prototipos. kaggle		
Predict students' dropout and academic success - Kaggle	Dataset de educación superior para predecir deserción y éxito académico, útil como benchmark. kaggle	Factores sociales, económicos, académicos, rendimiento, etiqueta dropout/success. kaggle	Kaggle - Predict students' dropout and academic success kaggle
Kaggle - Datasets	Buscador general de datasets en Kaggle para educación y analítica predictiva. kaggle+1	Miles de datasets con filtros por tema, formato y popularidad. kaggle+1	Kaggle Datasets