Proyecto: Machine Learning

**ACTIVIDAD**

# "Prototipo de Machine Learning para la Predicción del Rendimiento Estudiantil (Aprobado/Reprobado) basado en Habitos de Estudio, Desempeno Previo y Analitica Predictiva"

## Parte 1 — Plantilla de diseño del proyecto

| | |
|---|---|
| **Integrante del grupo:**<br>AMBAR ROCIO NAVARRO RIVERA | **Área disciplinar:**<br>Educacion, Ciencia de Datos e Inteligencia Artificial<br>Proyecto: PredictED-ML (Prediccion de Rendimiento Estudiantil mediante Random Forest) |

**FOTOS:**



## 1. El problema que quieren resolver.

**Describan el problema o necesidad concreta que identifican en su contexto:**
Describan un problema real en su contexto relacionado con:

- ☒ Transformación digital
- ☒ Brecha tecnológica
- ☒ Toma de decisiones basada en datos
- ☒ Uso de IA en educación
- ☒ Educación

### Introducción

La creciente disponibilidad de datos en entornos educativos contemporaneos fundamenta este proyecto orientado a la toma de decisiones pedagogicas tempranas impulsadas por Machine Learning. La investigacion transita desde enfoques meramente descriptivos hacia un prototipo predictivo y prescriptivo capaz de anticipar oportunamente si un estudiante aprobara o reprobara su periodo academico basandose en sus habitos de estudio, calificaciones acumuladas previas y dedicacion extracurricular.

En concordancia, se implementa un modelo supervisado Random Forest con ponderacion balanceada (class_weight='balanced') para apoyar la toma de decisiones docentes e institucionales frente a un desbalance del 5.3% de reprobacion en 5.000 observaciones.

De igual manera, el prototipo facilita el diseno de estrategias pedagogicas preventivas sustentadas en datos, optimizando el acompanamiento tutorial y potenciando la capacidad de accion docente mediante un simulador web interactivo en tiempo real.

Para la prediccion especifica del exito y riesgo academico, Alamo (2024) y Cardona & Arbelaez (2019) confirman que la IA y el Educational Data Mining identifican eficazmente patrones en conjuntos de datos educativos para gestionar la desercion mediante intervenciones personalizadas.

La literatura y experimentacion en este proyecto demuestran que un ensamble Random Forest supera ampliamente a modelos lineales (Regresion Logistica) y de vectores de soporte (SVM), logrando un Recall del 74% en la clase critica y un AUC-ROC de 0.94.

### Describe el problema antecedente:

En las instituciones educativas a nivel global y en la educacion superior, las altas tasas de reprobacion reiterada y desercion academica representan un problema critico. Tradicionalmente, la deteccion de estudiantes con bajo rendimiento se realiza al finalizar los periodos evaluativos, cuando las intervenciones pedagogicas resultan tardias.

Mediante el uso de repositorios abiertos de analitica educativa como el 'Student Performance Dataset' de Kaggle (5.000 observaciones), es posible estructurar pipelines reproducibles de preparacion de datos, entrenamiento y despliegue interactivo.

**1. Componentes Metodológicos Identificados (Línea de Base)**

- Unidad de Analisis: El estudiante individual y su trayectoria academica (habitos de estudio, autoevaluacion, notas previas y desempeno en examen).
- Variables Independientes (X_n): Horas de estudio semanales (Hours_Studied: 1 a 9 hrs), promedio de calificaciones previas (Previous_Scores: 0 a 100), horas de sueno (Sleep_Hours: 4 a 9 hrs), examenes practicos realizados (Sample_Question_Papers_Practiced: 0 a 9) y participacion extracurricular (Extracurricular_Activities: Yes/No codificado a 1/0).

    - Dimension de Rendimiento y Evaluacion: Calificacion del examen de corte (Exam_Score: escala 0 a 100) e Indice de Rendimiento General (Performance_Index: escala 0 a 100).
- Contexto Espacio-Temporal: Comunidad educativa en formacion; conjunto de 5.000 estudiantes con 16 atributos consolidados en el dataset Kaggle (licencia abierta ODbL).

**Problemática Detallada**

La problematica central radica en que los docentes y tutores carecen de herramientas en tiempo real para predecir que estudiantes estan en riesgo de reprobar antes de las semanas finales.

Este fenómeno genera tres desafíos metodológicos principales:

1. **Vacío de Generalización en Modelos de Deserción:** Los modelos analíticos tradicionales de las universidades son endógenos (solo miran al estudiante hacia adentro), lo que impide anticipar la deserción causada por factores exógenos del mercado o por asimetrías de pertinencia frente a la oferta nacional del SNIES.
2. **Obsolescencia del Análisis Curricular:** La verificación microcurricular de pertinencia se realiza bajo criterios cualitativos y subjetivos. No existen algoritmos de procesamiento de lenguaje natural (NLP) o de minería de datos que comparen la estructura curricular de una IES con los estándares normativos e históricos del SNIES de forma automatizada.
3. **Costos de Operación y Barreras de Acceso Técnico:** La recopilación manual de evidencias para el aseguramiento de la calidad consume meses de trabajo analítico por parte de los comités curriculares. Al no disponer de una interfaz unificada (un tablero de control predictivo y prescriptivo), las decisiones se toman con datos desactualizados, lo que compromete la rigurosidad científica exigida por los pares académicos del Consejo Nacional de Acreditación (CNA) y de la CONACES.

El proyecto de Machine Learning propuesto resuelve esta problemática al transformar datos abiertos crudos y dispersos en un motor de inferencia estadística parametrizado, estandarizando la evidencia técnico-científica necesaria para sustentar la viabilidad de cualquier programa académico en Colombia.

## 🎯 Variable objetivo (target)

### 👉 ¿Qué quieres predecir o analizar?

**Variable Objetivo (Dependiente $Y$):**

Condicion de Aprobacion del Estudiante: Clasificacion Binaria [Aprobado (Pass = 1) / Reprobado (Fail = 0)], calculada a partir del umbral Performance_Index >= 60 (Pass: 94.7%, Fail: 5.3%, Total: 5.000 estudiantes).

Variable objetivo principal: Condicion_Aprobacion_Pass_Fail (1 = Pass, 0 = Fail).
Tipo: Clasificacion Supervisada Binaria con clases fuertemente desbalanceadas.

- Clase Mayoritaria: Aprobado (Pass = 1) con 4.735 observaciones (94.7%).
- Clase Minoritaria / Critica: Reprobado (Fail = 0) con 265 observaciones (5.3%).

**Variable 1 (Tasa_Deserción_Proyectada):**

- La condicion Pass/Fail identifica tempranamente a aquellos estudiantes cuyo rendimiento acumulado proyecta reprobacion, permitiendo activar planes de refuerzo y tutorias inmediatas.
- El valor objetivo se modela penalizando los falsos positivos mediante class_weight='balanced' para maximizar la sensibilidad (Recall) en la clase minoritaria.

**Variable 2 (Índice_Pertinencia_Curricular):**

- Representa el nivel de alineación entre la oferta académica del programa y las necesidades del entorno productivo y social.
- Se expresa como un índice continuo (0–100), donde valores más altos indican mayor pertinencia.
- El índice se calcula mediante una métrica compuesta que integra:
    - Correspondencia entre competencias del currículo y perfiles ocupacionales.

- Brecha entre la oferta académica registrada en el SNIES y la demanda laboral identificada en Datos Abiertos.
- Tendencias de empleabilidad y sectores económicos prioritarios.
- Indicadores regionales de desarrollo y necesidades del mercado laboral.

### Variables Independientes

**Variables Independientes ($X_n$):**

- Dimension de Habitos de Estudio: Horas de estudio semanales (Hours_Studied) y horas de sueno (Sleep_Hours).
- Dimension de Trayectoria Academica: Promedio de notas previas acumuladas (Previous_Scores) y talleres de practica (Sample_Question_Papers_Practiced).
- Dimension Co-curricular y Evaluacion: Actividades extracurriculares (Extracurricular_Activities) y puntaje en examen de corte (Exam_Score).
- Dimension de Explicabilidad: Importancia de variables extraida del Random Forest (Previous_Scores: 43.2%, Hours_Studied: 28.1%, Exam_Score: 18.4%).
- Contexto del Estudio: 5.000 observaciones completas sin datos nulos ni duplicados, normalizadas mediante StandardScaler para optimizar la convergencia.

**NOTA: identifica claramente las fuentes oficiales (SNIES, OLE, DANE y Datos Abiertos) y contempla tanto factores académicos como socioeconómicos y territoriales que influyen en la deserción estudiantil y la pertinencia curricular.**

### Pregunta de investigación (orientada a ML):

### ¿Qué quieres predecir, clasificar o descubrir?

En que medida un modelo de Machine Learning supervisado (Random Forest con balanceo de clases) entrenado con habitos de estudio y calificaciones previas permite predecir tempranamente la condicion de aprobacion o reprobacion estudiantil con un AUC-ROC superior a 0.85 y un Recall >= 70% en la clase en riesgo, facilitando intervenciones pedagogicas oportunas?

### ¿A quién impacta?

El proyecto impacta directamente a los estudiantes en riesgo academico, facilitandoles apoyo antes de los examenes definitivos; a los docentes y tutores, dotandolos de un simulador predictivo; y a las instituciones educativas, reduciendo las tasas de fracaso y desercion escolar.

Asimismo, beneficia a los equipos de bienestar estudiantil y coordinacion academica mediante recomendaciones prescriptivas accionables.

El principal aporte radica en transformar datos de comportamiento y rendimiento en alertas tempranas automatizadas y explicables en una aplicacion web interactiva (Streamlit).

## 2. Arquitectura de IA y toma de decisión tecnológica

### MODELO DE MACHINE LEARNING

**¿Tipo de enfoque? Marquen una [X] y justifiquen:**

| | | | | | |
|---|---|---|---|---|---|
| [X] | MODELOS SUPERVISADOS (con datos etiquetados)<br>Se emplea un clasificador Random Forest supervisado para predecir la condicion binaria de aprobacion o reprobacion (Pass/Fail) a partir de variables de habitos de estudio y notas previas. | [X ] | NO supervisados (sin target)<br>Se utiliza analisis exploratorio (EDA) y perfilado automatico con YData Profiling para descubrir correlaciones, patrones de distribucion y el desbalance de clases. | [ ] | No constituye el enfoque principal del proyecto. Como trabajo futuro podría incorporarse para optimizar estrategias de intervención institucional mediante agentes inteligentes o asistentes basados en Modelos de Lenguaje (LLM) que automaticen la generación de recomendaciones para la formulación de Documentos Maestros. |

**NOTA: (para que nadie se pierda)**

- **¿Quieres predecir la deserción o la pertinencia curricular?** → Aprendizaje Supervisado.
- **¿Quieres descubrir grupos de programas o instituciones con comportamientos similares?** → Aprendizaje No Supervisado.
- **¿Quieres recomendar estrategias institucionales basadas en los resultados?** → Analítica Prescriptiva.
- **¿Quieres automatizar la generación de informes o recomendaciones mediante IA generativa?** → Modelos Preentrenados (trabajo futuro).

### 🎯 Modelo seleccionado

El proyecto implementa un modelo de ensamble Random Forest optimizado (n_estimators=100, max_depth=5, min_samples_split=10, class_weight='balanced', random_state=42).

La experimentacion comparo Random Forest frente a Regresion Logistica y Support Vector Machines (SVM), demostrando la superioridad del ensamble en datasets educativos con desbalance.

El modelo final alcanza un Accuracy del 92.1%, Recall del 74% para la clase Fail, Precision de 76%, F1-score de 75% y un AUC-ROC de 0.94.

### Modelos Supervisados

- “Random Forest”
- XGBoost
- LightGBM
- CatBoost
- Extra Trees
- “Gradient Boosting”
- AdaBoost
- “Decision Tree”
- “Support Vector Machine (SVM)”
- “K-Nearest Neighbors (KNN)”
- “Ridge Regression”
- “Lasso Regression”
- “Regresión Lineal”
- “Regresión Logística”
- Elastic Net
- Redes Neuronales (MLP)

**Modelos No Supervisados**

- “K-Means”
- MiniBatch K-Means
- “DBSCAN”
- HDBSCAN
- Agglomerative Clustering
- Gaussian Mixture Models (GMM)
- Spectral Clustering
- “PCA”
- UMAP
- t-SNE
- Isolation Forest
- Local Outlier Factor (LOF)

**La selección del modelo óptimo se realizará mediante métricas de desempeño como:**

- Accuracy
- Precision
- Recall
- F1-Score
- ROC-AUC
- MAE
- RMSE
- $R^2$

**Dependiendo de la naturaleza de cada variable objetivo.**

El framework comparará automáticamente el rendimiento de cada algoritmo mediante validación cruzada y métricas de evaluación, seleccionando el modelo con mejor capacidad predictiva e interpretativa para cada escenario de análisis.

**Justificación**

- **¿Qué tipo de datos tienes?**

El prototipo utiliza el conjunto de datos estructurado 'Student Performance Dataset' (5.000 filas x 16 columnas) de Kaggle.

La variable objetivo es la condicion binaria de aprobacion (Pass=1 / Fail=0).

- **¿Qué problema resuelve este modelo?**

Resuelve el problema de la deteccion tardia del fracaso academico, permitiendo al docente evaluar el riesgo del estudiante en cualquier momento del ciclo.

- **¿Por qué es la mejor opción?**

Random Forest fue la mejor opcion porque maneja interacciones no lineales, no se ve afectado por outliers, provee interpretabilidad directa (feature importance) y resuelve el desbalance con class_weight='balanced'.

## Arquitectura de Datos

Para un proyecto de investigación, la arquitectura de datos se entiende mucho mejor en formato tabular. Además, deja más claro el flujo **ETL + Machine Learning + Analítica Prescriptiva**.

### Arquitectura de Datos del Framework

| Fase | Proceso | Fuentes / Tecnologías | Salida Esperada |
|---|---|---|---|
| **1. Captura de Datos** | Carga del dataset de 5.000 observaciones desde el repositorio abierto de Kaggle o archivo local CSV. | Kaggle Hub API / CSV local (student_performance_dataset.csv, licencia ODbL). | DataFrame consolidado con 16 atributos sobre habitos de estudio y rendimiento. |
| **2. Integración (ETL)** | Limpieza de nulos (0 encontrados), eliminacion de duplicados y codificacion binaria de Extracurricular_Activities. | Python 3.10, Pandas, NumPy, StandardScaler. | Matrices preprocesadas X_train, X_test, y_train, y_test con split estratificado 80/20. |
| **3. Preparación de Datos** | Escalado de variables continuas y configuracion del parametro class_weight='balanced'. | Scikit-Learn (preprocessing, model_selection). | Conjuntos de datos listos para el entrenamiento supervisado. |
| **4. Analítica Supervisada** | Entrenamiento del Random Forest con 100 arboles de decision y profundidad maxima de 5. | Scikit-Learn RandomForestClassifier. | Modelo entrenado con reproducibilidad verificada (random_state=42). |
| **5. Analítica No Supervisada** | Perfilado automatico con YData Profiling y generacion de matrices de correlacion. | YData Profiling, Seaborn, Matplotlib. | Reporte integral de EDA con analisis de distribuciones y multicolinealidad. |
| **6. Selección Automática del Modelo** | Evaluacion con validacion cruzada y metricas de clasificacion (Accuracy, Precision, Recall, F1, ROC-AUC). | Scikit-Learn classification_report, roc_auc_score, confusion_matrix. | Recall de 74% en Fail y AUC-ROC de 0.94. |
| **7. Analítica Predictiva** | Calculo de feature importance para explicar que factores determinan el exito. | Previous_Scores (43.2%), Hours_Studied (28.1%), Exam_Score (18.4%). | Factores jerarquizados para la toma de decisiones pedagogicas. |
| **8. Analítica Prescriptiva** | Generacion de recomendaciones pedagogicas prescriptivas personalizadas para el estudiante. | Motor prescriptivo basado en umbrales de probabilidad y horas de estudio. | Ficha de tutoria con plan de refuerzo y sugerencia de dedicacion horaria. |
| **9. Visualización y Toma de Decisiones** | Publicacion de la aplicacion en Streamlit Community Cloud y Landing Page en GitHub Pages. | Streamlit 1.28, HTML5, CSS3, JavaScript, GitHub Pages. | Plataforma publica interactiva con simulador en tiempo real y video explicativo. |

### Fuentes Oficiales Integradas

| Entidad | Información | Acceso |
|---|---|---|
| Kaggle: Student Performance | 5.000 observaciones de estudiantes con habitos y calificaciones | https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset |
| Cuaderno Jupyter | Project_ML_PRE.ipynb con el flujo reproducible completo | https://github.com/Ambar1920/Project_ML_PRE.git |
| Streamlit Web App | Simulador interactivo y comparativa de modelos en la nube | https://Project_ML_PRE.streamlit.app |
| GitHub Pages | Landing page responsive institucional con metodologia CRISP-ML | https://Ambar1920.github.io/Project_ML_PRE/ |

| | | |
|---|---|---|
| Video Interactivo BRAG | Presentacion ejecutiva de 1:15 minutos con sintesis de voz en espanol | https://ambar1920.github.io/Project_ML_PRE/#video |

### Valor agregado de esta arquitectura

Esta propuesta trasciende la construcción de un simple modelo predictivo. El valor agregado radica en la conformación de un ecosistema integral de Inteligencia Artificial aplicada a la educación, diseñado bajo los más altos estándares de reproducibilidad, usabilidad y rigor metodológico. Sus pilares fundamentales son:

1. **Rigor Metodológico con CRISP-ML(Q)**: La arquitectura no solo sigue el flujo estándar de ciencia de datos, sino que incorpora la dimensión de *Calidad (Quality)* de CRISP-ML(Q). Esto garantiza que cada fase (desde la ingesta y el EDA automatizado hasta el despliegue) esté documentada, validada y libre de *data leakage*, asegurando la confiabilidad de las predicciones.
2. **Democratización del Dato y Usabilidad**: Al integrar una Landing Page en GitHub Pages con una Aplicación Streamlit, se cierra la brecha entre la complejidad técnica y el usuario final (docentes, orientadores o administrativos). El simulador interactivo permite que actores no técnicos puedan introducir variables y comprender el impacto en el rendimiento estudiantil sin necesidad de conocer código, fomentando una cultura basada en datos.
3. **Trazabilidad y Reproducibilidad Total (Open Science)**: Todo el ciclo de vida del modelo está versionado y disponible en un repositorio GitHub organizado. Cualquier evaluador o investigador puede clonar el proyecto, ejecutar el cuaderno Jupyter y obtener los mismos resultados, cumpliendo con los principios de ciencia abierta y transparencia algorítmica exigidos en la investigación académica moderna.
4. **Comunicación Ejecutiva Potenciada por IA**: El uso estratégico de herramientas de IA generativa para la creación del video de 1:15 minutos demuestra una competencia transversal clave del curso: la capacidad de sintetizar hallazgos técnicos complejos en mensajes claros, persuasivos y accesibles para la toma de decisiones institucionales.
5. **Enfoque Ético y de Intervención Temprana**: Más allá de la métrica de *Accuracy* o *ROC-AUC*, la arquitectura está diseñada con un propósito social claro: actuar como un sistema de alerta temprana. Al identificar patrones de riesgo académico de manera automatizada, el prototipo habilita a las instituciones educativas para pasar de un modelo reactivo a uno preventivo, priorizando el acompañamiento pedagógico sobre la sanción.

### 3. Los datos que necesitarían

| ¿Qué tipo de datos necesitarían? | ¿De dónde los obtendrían? |
|---|---|
| **Datos académicos:** matrícula, permanencia, deserción, graduación, cobertura, programas académicos, modalidad, nivel de formación, acreditación, Registro Calificado, Núcleos Básicos del Conocimiento (NBC), características institucionales y planta docente. | **SNIES (Sistema Nacional de Información de la Educación Superior)** https://snies.mineducacion.gov.co |
| **Datos laborales:** empleabilidad de graduados, salarios de enganche, inserción laboral, demanda ocupacional y sectores productivos. | **Observatorio Laboral para la Educación (OLE)** https://ole.mineducacion.gov.co |
| **Datos demográficos y socioeconómicos:** población, proyecciones demográficas, pobreza multidimensional, desempleo, informalidad, PIB regional, indicadores sociales y económicos. | **DANE** https://www.dane.gov.co |
| **Datos abiertos gubernamentales:** educación, economía, empleo, territorio, indicadores regionales, desarrollo social y variables complementarias para enriquecer los modelos. | **Portal Nacional de Datos Abiertos** https://www.datos.gov.co |
| **Datos geográficos:** ubicación de Instituciones de Educación Superior, municipios, departamentos y regiones para análisis espacial. | Datos Abiertos Colombia, DANE y servicios cartográficos abiertos (GeoJSON). |
| **Dataset integrado del proyecto:** consolidación automática de todas las fuentes oficiales mediante procesos ETL, generando un repositorio estructurado para entrenamiento y validación de modelos. | Framework desarrollado en Python mediante consumo de APIs REST y archivos CSV/JSON provenientes de las fuentes oficiales. |

### Proceso ETL (Extract, Transform, Load)

Antes de entrenar los modelos de Machine Learning, los datos serán preparados mediante un proceso ETL automatizado que garantizará la calidad, consistencia e integración de la información proveniente de múltiples fuentes oficiales.

### Pipeline Inteligente del Framework

1. Definir las variables objetivo (**Tasa de Deserción Proyectada** e **Índice de Pertinencia Curricular**).
2. Consumir automáticamente los datasets oficiales mediante APIs REST (SNIES, Datos Abiertos Colombia, DANE y OLE).
3. Integrar la información académica, laboral, socioeconómica y territorial en un único repositorio analítico.
4. Validar la calidad de los datos mediante reglas de negocio (duplicados, consistencia, formatos y valores fuera de rango).
5. Realizar procesos de limpieza, transformación e ingeniería de características (*Feature Engineering*).
6. Seleccionar automáticamente las variables más relevantes mediante técnicas de selección de características.
7. Dividir los datos en conjuntos de entrenamiento, validación y prueba utilizando validación cruzada.
8. Comparar automáticamente múltiples algoritmos mediante **PyCaret** y **FLAML**, evaluando modelos supervisados y no supervisados.
9. Seleccionar el mejor modelo según métricas de desempeño e interpretabilidad.
10. Publicar los resultados en una plataforma **Streamlit** con dashboards interactivos, predicciones y recomendaciones prescriptivas para apoyar la toma de decisiones institucionales.

### Tener presente ¿Qué significa ETL?

- **Extract (Extraer):** Obtener datos desde múltiples fuentes oficiales mediante APIs, servicios REST y conjuntos de datos abiertos.
- **Transform (Transformar):** Limpiar, integrar, normalizar y preparar los datos para el análisis y entrenamiento de modelos.
- **Load (Cargar):** Consolidar la información en un repositorio estructurado para Machine Learning, visualización y analítica prescriptiva.

### Aplicación en el proyecto

### Extract — ¿De dónde obtienen los datos?

Los datos serán obtenidos automáticamente mediante consumo de APIs y servicios abiertos de entidades oficiales del Estado colombiano.

| Fuente | Tipo de información | Acceso |
|---|---|---|
| Kaggle Dataset: student-performance-dataset | Horas de estudio, notas previas, sueno, simulacros y notas de examen. | https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset |
| Repositorio GitHub del Proyecto | Codigo fuente, notebook .ipynb, landing page y documentacion tecnica. | https://github.com/Ambar1920/Project_ML_PRE.git |
| Streamlit Community Cloud | Aplicacion web interactiva en produccion con simulador predictivo. | https://Project_ML_PRE.streamlit.app |
| Documento Tecnico PDF | Memoria tecnica completa de la investigacion para evaluacion de maestria. | documento_tecnico.pdf |
| Video Interactivo de Presentacion | Presentacion de 1:15 minutos en 5 capitulos generada con IA y sintesis de voz. | https://ambar1920.github.io/Project_ML_PRE/#video |

La extracción será realizada mediante bibliotecas como **Requests**, **Pandas**, **Sodapy** (API Socrata) y procesos automatizados desarrollados en Python.

### TRANSFORMA — ¿CÓMO PREPARAN LOS DATOS?

☑ Limpieza de datos (duplicados e inconsistencias)
☑ Tratamiento de valores faltantes
☑ Integración de múltiples fuentes

☑ Conversión de variables categóricas
☑ Normalización y escalamiento
☑ Ingeniería de características (*Feature Engineering*)
☑ Selección automática de variables
☑ Reducción de dimensionalidad (PCA, UMAP)
☑ Detección de valores atípicos

**✍ Describe:**
Durante esta etapa crítica del flujo de trabajo, se procesaron los **5.000 registros** del conjunto de datos abierto, aplicando de manera rigurosa los pasos anteriores para garantizar la calidad, consistencia y compatibilidad de la información con los algoritmos de Machine Learning. El procedimiento se ejecutó de la siguiente manera:

1. **Limpieza y tratamiento de valores**: Se auditaron los 5.000 registros para identificar y gestionar valores faltantes, duplicados o inconsistentes, asegurando la integridad del conjunto de datos antes de cualquier operación de modelado.
2. **Conversión de variables categóricas**: Variables como Extracurricular_Activities se codificaron a formato binario (1 para participación activa, 0 para no participación). Esto permite que el algoritmo procese matemáticamente esta característica sin asumir un orden jerárquico inexistente entre las categorías.
3. **Normalización y escalamiento**: Se aplicó estandarización (StandardScaler) a las variables continuas (ej. *Horas de estudio*, *Calificaciones previas*, *Horas de sueño*). Esta transformación centra los datos en una media de 0 y una desviación estándar de 1, garantizando que todas las variables contribuyan equitativamente al modelo y evitando que aquellas con rangos numéricos más amplios dominen injustamente la función de optimización.
4. **Ingeniería de características (Feature Engineering) y derivación del Target**: Se construyó la variable objetivo binaria Pass/Fail (Aprobado/Reprobado) a partir de los indicadores de rendimiento continuo originales del dataset (ej. *Performance Index*). Se definió un umbral pedagógico lógico ($\geq 65$) para binarizar el resultado. Esta decisión transforma el problema en una tarea de **clasificación supervisada**, alineándose directamente con el objetivo del proyecto: identificar de manera temprana a estudiantes en riesgo de fracaso académico.

**◈ Load — ¿Cómo dejan los datos listos?**
☑ Dataset estructurado para Machine Learning
☑ Repositorio analítico integrado
☑ Base de datos para visualización
☑ Dashboards interactivos
☑ Modelos entrenados

**✍ Resultado esperado:**
El resultado es un pipeline reproducible con matrices de entrenamiento y prueba perfectamente balanceadas mediante class_weight='balanced' y serializadas.

**🧠 Nota clave**
**Los datos son el activo estratégico del proyecto.**

- Datos de alta calidad permiten construir modelos más precisos, interpretables y confiables.
- La integración de múltiples fuentes oficiales incrementa la capacidad predictiva y analítica del framework.
- La actualización automática mediante APIs garantiza información vigente para apoyar la toma de decisiones basada en evidencia.

**🔍 ANÁLISIS EXPLORATORIO DE DATOS (EDA)**
**¿Qué harías antes de aplicar los modelos?**
☑ Limpieza de datos
☑ Tratamiento de valores faltantes
☑ Integración de fuentes
☑ Visualización interactiva
☑ Análisis descriptivo
☑ Correlación entre variables
☑ Identificación de valores atípicos
☑ Balance de variables objetivo
☑ Reducción de dimensionalidad

☑ Segmentación preliminar

**Describe:**
El EDA funcionó como fase diagnóstica bajo la metodología CRISP-ML(Q). Se constató la integridad del dataset y se identificó una correlación positiva moderada ($r \approx 0.42$) entre Hours_Studied y Exam_Score, validando la hipótesis pedagógica del esfuerzo académico. Un hallazgo crítico fue el desbalance de la clase minoritaria "Fail" (5.3%), lo que justificó técnicamente el uso de estrategias de balanceo (ej. class_weight='balanced') para evitar que el modelo ignore a los estudiantes en riesgo. Como soporte visual y estadístico, se generaron histogramas, mapas de calor de correlación y un reporte automatizado exhaustivo con YData Profiling.

## DESAFÍOS (NIVEL ESTRATÉGICO)

**• Calidad de datos • Acceso • Integración • Sesgo**

**Matriz DOFA — Gestión de Datos y Modelado en Predicción de Rendimiento Estudiantil**

| Factor | Fortalezas (Interno +) | Oportunidades (Externo +) | Debilidades (Interno -) | Amenazas (Externo -) |
|---|---|---|---|---|
| **Calidad de los datos** | Uso de herramientas automatizadas (YData Profiling) para auditar la integridad de los 5.000 registros, garantizando la ausencia de nulos y duplicados antes del modelado. | Enriquecer el dataset en fases futuras con variables de contexto socioeconómico o salud mental para mejorar la potencia predictiva del modelo. | Desbalance extremo de clases (solo 5.3% de la clase "Fail"), lo que obliga a usar técnicas de mitigación para evitar que el modelo ignore a los estudiantes en riesgo. | La naturaleza anonimizada y sintética de algunos datasets abiertos puede no capturar la complejidad y el ruido de un entorno educativo real. |
| **Acceso a la información** | Utilización de un dataset de código abierto (Kaggle) que garantiza la **reproducibilidad total** del proyecto, permitiendo que cualquier evaluador clone y ejecute el código sin barreras legales. | Migrar el prototipo exitoso a un entorno de producción real, utilizando datos históricos de una institución educativa (previo consentimiento informado). | Dependencia inicial de una fuente externa (Kaggle); si el enlace cambia, se requiere un mecanismo *fallback* (como el generado en el código) para evitar fallos. | Cambios futuros en las políticas de licencia o la eliminación del dataset de la plataforma podrían afectar la trazabilidad a largo plazo del proyecto. |
| **Integración y Preparación (ETL)** | Pipeline ETL robusto y documentado en el Notebook (codificación binaria, StandardScaler, partición estratificada) que previene eficazmente la fuga de datos (*data leakage*). | Automatizar este pipeline ETL en la nube (ej. GitHub Actions) para cuando el modelo se conecte en tiempo real a un sistema de gestión académica (LMS). | La ingeniería de características (*Feature Engineering*) se limita a las variables disponibles en el dataset, requiriendo mayor procesamiento si se añaden variables no estructuradas. | Incompatibilidad de formatos o esquemas si se intenta migrar este prototipo a bases de datos institucionales legacy o sistemas cerrados. |
| **Sesgo y Ética en IA** | Implementación de class_weight='balanced' en el Random Forest y un enfoque pedagógico de **alerta temprana**, no punitivo, para proteger al estudiante. | Incorporar técnicas de Inteligencia Artificial Explicable (XAI), como SHAP o LIME, en el despliegue para mostrar al docente *por qué* se marcó a un estudiante como "en riesgo". | El modelo asume correlaciones lineales (ej. más horas de estudio = mejor nota), ignorando factores no medibles en el dataset como el apoyo familiar o el estrés. | Estigmatización del estudiante si la institución usa la predicción de "Reprobado" como una sentencia definitiva en lugar de una oportunidad de intervención pedagógica. |

## 4. Objetivos SMART — Diseño del Proyecto de Inteligencia Artificial

### Objetivo General

Diseñar, entrenar y desplegar un prototipo de Machine Learning supervisado (Random Forest) para predecir el rendimiento estudiantil (Aprobado/Reprobado) a partir de hábitos de estudio y calificaciones previas, logrando un AUC-ROC ≥0.85 y desplegándolo en Streamlit Community Cloud.

### Desglose SMART del Objetivo General:

- Específico (S): Entrenar un modelo Random Forest con ponderación balanceada para identificar estudiantes en riesgo de reprobación.
- Medible (M): Alcanzar un AUC-ROC ≥0.85 y un Recall ≥0.90 en la clase minoritaria (Fail).
- Alcanzable (A): Utilizando un dataset consolidado de 5.000 registros y técnicas de mitigación de desbalance (class_weight='balanced').
- Relevante (R): Aporta una herramienta de alerta temprana para la toma de decisiones pedagógicas preventivas.
- Temporal (T): Desarrollado, documentado y desplegado en el plazo establecido por el curso de Machine Learning.

### ☑ Objetivos Específicos

1. **Problema:** Las instituciones educativas necesitan herramientas predictivas tempranas que permitan intervenir antes de que los estudiantes reprueben sus asignaturas, transformando un modelo reactivo en uno preventivo.
2. **Modelo de Machine Learning:** Implementar un modelo de Aprendizaje Supervisado (Random Forest) complementado con un Análisis Exploratorio de Datos (EDA) automatizado y un simulador interactivo para la inferencia en tiempo real.
3. **Datos:** Analizar 5.000 registros del *Student Performance Dataset* (Kaggle), procesando variables de dedicación horaria, calificaciones previas acumuladas y desempeño en exámenes mediante un pipeline ETL robusto.
4. **Riesgos y Mitigación:**
    - ***Riesgo:*** Desbalance severo de clases (94.7% Pass vs 5.3% Fail). *Mitigación:* Uso del parámetro class_weight='balanced' en el Random Forest.
    - ***Riesgo:*** Data leakage por inclusión de notas finales en predicciones tempranas. *Mitigación:* Exclusión de variables post-facto (ADR-003).
    - ***Riesgo:*** Sobreajuste (Overfitting). *Mitigación:* Control de hiperparámetros (max_depth=5, min_samples_split=10) y validación cruzada estratificada.
5. **Presentación y Despliegue:** Poner a disposición de docentes y coordinadores un prototipo web funcional (Streamlit) que permita anticipar el riesgo académico y generar fichas de recomendación pedagógica.

### 5. La dimensión ética del proyecto

| Consideración ética | ¿Cómo lo abordarían? | ¿Aplica? |
|---|---|---|
| **Privacidad y protección de datos** | El proyecto utiliza datos totalmente anonimizados de acceso abierto (Kaggle), sin incluir nombres, identificaciones ni datos personales sensibles. | **Sí** |
| **Sesgo en los datos o poblaciones subrepresentadas** | No se incluyeron variables sociodemográficas sensibles (género, etnia o nivel socioeconómico) para evitar sesgos discriminatorios en la predicción. | **Sí** |
| **Transparencia y explicabilidad del modelo** | Se garantiza explicabilidad mediante *feature importance* (ej. *Previous_Scores* 43.2%, *Hours_Studied* 28.1%), asegurando que las recomendaciones sean transparentes para el docente. | **Sí** |
| **Riesgo de estigmatización institucional** | El sistema clasifica el riesgo únicamente como un insumo pedagógico formativo y preventivo, sin emitir calificaciones definitivas ni etiquetar negativamente al estudiante. | **Sí** |
| **Supervisión humana y toma de decisiones** | Supervisión humana obligatoria: el prototipo asiste al docente, quien conserva siempre la decisión pedagógica final y el diseño del plan de apoyo. | **Sí** |

## Bibliografía


Alalawi, K., Athauda, R., & Chiong, R. (2023). Contextualizing the current state of research on the use of machine learning for student performance prediction: A systematic literature review. *Engineering Reports, 5*(12), Article e12699. https://doi.org/10.1002/eng2.12699

Albreiki, B., Zaki, N., & Alashwal, H. (2021). A systematic literature review of student performance prediction using machine learning techniques. *IEEE Access, 9*, 103719–103739. https://doi.org/10.1109/ACCESS.2021.3082813

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Chui, K. T., Fung, D. C. L., Lytras, M. D., & Lam, T. M. (2020). Predicting at-risk university students in a virtual learning environment via a machine learning algorithm. *Computers in Human Behavior, 107*, Article 105884. https://doi.org/10.1016/j.chb.2020.105884

Kuzilek, J., Hlosta, M., & Zdrahal, Z. (2017). Open university learning analytics dataset. *Scientific Data, 4*, Article 170171. https://doi.org/10.1038/sdata.2017.171

Miguéis, V. L., Benítez, J. M., & van der Aalst, W. M. P. (2018). Early segmentation of students according to their academic performance: A predictive modelling approach. *Decision Support Systems, 115*, 55–64. https://doi.org/10.1016/j.dss.2018.09.005

Ouyang, F., Wu, M., Zheng, L., Zhang, L., & Jiao, P. (2023). Integration of artificial intelligence performance prediction and learning analytics to improve student learning in online engineering course. *International Journal of Educational Technology in Higher Education, 20*, Article 4. https://doi.org/10.1186/s41239-022-00372-4

Rastrollo-Guerrero, J. L., Gómez-Pulido, J. A., & Durán-Domínguez, A. (2020). Analyzing and predicting students' performance by means of machine learning: A review. *Applied Sciences, 10*(3), Article 1042. https://doi.org/10.3390/app10031042

Romero, C., & Ventura, S. (2010). Educational data mining: A review of the state of the art. *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews), 40*(6), 601–618. https://doi.org/10.1109/TSMCC.2010.2053532

Romero, C., & Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. *WIREs Data Mining and Knowledge Discovery, 10*(3), Article e1355. https://doi.org/10.1002/widm.1355

Sghir, N., Adadi, A., & Lahmer, M. (2023). Recent advances on predicting student performance using machine learning: A systematic review. *Education and Information Technologies, 28*, 10503–10528. https://doi.org/10.1007/s10639-022-11139-6

Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction, 3*(2), 392–428. https://doi.org/10.3390/make3020020

Tomasevic, N., Gvozdenovic, N., & Vranes, S. (2020). An overview and comparison of supervised data mining techniques for student exam performance prediction. *Computers & Education, 143*, Article 103676. https://doi.org/10.1016/j.compedu.2019.103676

Waheed, H., Hassan, S.-U., Aljohani, N. R., Hardman, J., Alelyani, S., & Nawaz, R. (2020). Predicting academic performance of students from VLE big data using deep learning models. *Computers in Human Behavior, 104*, Article 106189. https://doi.org/10.1016/j.chb.2019.106189

Wang, X., Zhao, Y., Li, C., & Ren, P. (2023). ProbSAP: A comprehensive and high-performance system for student academic performance prediction. *Pattern Recognition, 137*, Article 109125. https://doi.org/10.1016/j.patcog.2022.109125

Xu, J., Moon, K. H., & van der Schaar, M. (2017). A machine learning approach for tracking and predicting student performance in degree programs. *IEEE Journal of Selected Topics in Signal Processing, 11*(5), 742–753. https://doi.org/10.1109/JSTSP.2017.2692564

Yağcı, M. (2022). Educational data mining: Prediction of students' academic performance using machine learning algorithms. *Smart Learning Environments, 9*, Article 11. https://doi.org/10.1186/s40561-022-00192-z

## Estado del arte

### Minería de datos educativos

La minería de datos educativos aplica técnicas estadísticas, de aprendizaje automático y de visualización para analizar información generada en contextos educativos. Su finalidad es descubrir patrones, relaciones y tendencias que permitan mejorar los procesos de enseñanza, aprendizaje, evaluación y gestión institucional (Romero & Ventura, 2010).

Entre sus principales aplicaciones se encuentran la predicción de calificaciones, la identificación de estudiantes en riesgo, la detección de deserción, la personalización del aprendizaje y la recomendación de recursos educativos (Romero & Ventura, 2020). La analítica del aprendizaje complementa este enfoque al centrarse en la recopilación, análisis y visualización de datos sobre los estudiantes y sus contextos de aprendizaje, con el propósito de mejorar la experiencia educativa y el acompañamiento pedagógico.

En este marco, la predicción del rendimiento estudiantil se configura como una tarea de aprendizaje supervisado, en la cual el sistema aprende de datos históricos etiquetados para estimar una variable de interés. En el presente proyecto, la variable objetivo corresponde a la condición de aprobación o reprobación, expresada como una clasificación binaria.

### Variables predictoras del rendimiento

La literatura identifica el desempeño académico previo como uno de los predictores más consistentes del rendimiento futuro. Las calificaciones acumuladas, los resultados de evaluaciones parciales y el desempeño en actividades prácticas permiten estimar la trayectoria académica del estudiante y anticipar posibles resultados (Xu et al., 2017).

Los hábitos de estudio también han sido reconocidos como factores relevantes. La dedicación semanal al estudio, la realización de ejercicios prácticos, la participación en actividades complementarias y la organización del tiempo pueden influir en la comprensión de los contenidos y en la preparación para las evaluaciones (Rastrollo-Guerrero et al., 2020).

En entornos virtuales, las interacciones con plataformas de aprendizaje han demostrado ser predictoras del desempeño. Waheed et al. (2020) evidenciaron que los patrones de acceso, participación y uso de recursos pueden anticipar resultados académicos mediante modelos de aprendizaje profundo. De forma similar, Chui et al. (2020) emplearon datos de interacción en entornos virtuales para identificar estudiantes en riesgo, reforzando la importancia del comportamiento de aprendizaje como complemento de las medidas tradicionales de rendimiento.

No obstante, el rendimiento académico no depende exclusivamente de factores individuales. Variables socioeconómicas, familiares, psicológicas, institucionales y territoriales pueden condicionar las oportunidades de aprendizaje y afectar el desempeño estudiantil (Rastrollo-Guerrero et al., 2020). Por ello, los modelos que solo incorporan variables académicas pueden presentar limitaciones en su capacidad explicativa y en su generalización a otros contextos.

En el proyecto propuesto, las variables independientes incluyen horas de estudio semanales, promedio de calificaciones previas, horas de sueño, realización de exámenes prácticos y participación en actividades extracurriculares. Esta selección permite modelar dimensiones relacionadas con el esfuerzo académico, la trayectoria previa, el bienestar y la participación estudiantil.

### Modelos de aprendizaje automático

El aprendizaje automático supervisado constituye el enfoque predominante en la predicción del rendimiento estudiantil. Entre los algoritmos más utilizados se encuentran los árboles de decisión, los bosques aleatorios, las máquinas de vectores de soporte, los modelos bayesianos, la regresión logística, los vecinos más cercanos, las redes neuronales artificiales y los métodos de *boosting* (Sghir et al., 2023).

Los árboles de decisión son modelos intuitivos que representan reglas de decisión mediante estructuras jerárquicas. Su principal ventaja radica en la facilidad de interpretación; sin embargo, pueden presentar problemas de sobreajuste cuando crecen excesivamente. Los bosques aleatorios abordan esta limitación mediante la combinación de múltiples árboles entrenados sobre subconjuntos aleatorios de datos y variables (Breiman, 2001).

Breiman (2001) demostró que los bosques aleatorios reducen la varianza asociada a los árboles individuales y mejoran la estabilidad predictiva. Esta característica los convierte en una alternativa robusta para conjuntos de datos con relaciones complejas, interacciones entre variables y presencia de valores atípicos.

Miguéis et al. (2018) evaluaron distintos métodos de clasificación para segmentar tempranamente a estudiantes según su desempeño académico. Los resultados evidenciaron que los bosques aleatorios superaron a otros métodos, incluyendo árboles de decisión, máquinas de vectores de soporte, modelos bayesianos, *bagging* y *boosting*. Estos hallazgos respaldan la selección de *Random Forest* como modelo principal en el prototipo propuesto.

Sghir et al. (2023) señalaron que las redes neuronales artificiales, los bosques aleatorios y los métodos basados en *gradient boosting* son los enfoques más frecuentes en la predicción del rendimiento estudiantil. Asimismo, destacaron que la validación rigurosa de los modelos, la prevención del sobreajuste y la evaluación con métricas adecuadas son condiciones indispensables para garantizar resultados confiables.

En el proyecto, se implementa un modelo de *Random Forest* con 100 árboles, profundidad máxima de cinco, mínimo de diez muestras para dividir un nodo y ponderación balanceada de clases. Estos hiperparámetros buscan controlar el sobreajuste, mejorar la generalización y atender el desbalance existente entre las clases de aprobación y reprobación.

**Desbalance de clases**

El desbalance de clases constituye uno de los principales desafíos metodológicos en la predicción de reprobación o bajo rendimiento académico. En muchos contextos educativos, la mayoría de los estudiantes aprueba, mientras que la clase minoritaria corresponde precisamente al grupo de interés: aquellos que requieren acompañamiento o intervención temprana (Alalawi et al., 2023).

Cuando existe un desbalance severo, la exactitud global puede resultar engañosa. Un modelo que predice mayoritariamente la clase dominante puede alcanzar una precisión alta sin identificar adecuadamente los casos críticos. Por ello, la literatura recomienda evaluar los modelos mediante sensibilidad o *recall*, precisión, *F1-score*, matriz de confusión y área bajo la curva ROC (*AUC-ROC*) (Albreiki et al., 2021; Ouyang et al., 2023).

La sensibilidad o *recall* es especialmente relevante en sistemas de alerta temprana, pues mide la proporción de estudiantes en riesgo que el modelo logra identificar. Una alta sensibilidad reduce la probabilidad de omitir estudiantes que requieren apoyo pedagógico, aunque puede incrementar los falsos positivos (Alalawi et al., 2023).

Las estrategias para abordar el desbalance incluyen la ponderación de clases, el sobremuestreo de la clase minoritaria, el submuestreo de la clase mayoritaria y el ajuste de umbrales de decisión (Rastrollo-Guerrero et al., 2020). En el proyecto, se emplea el parámetro class_weight='balanced' en el modelo *Random Forest*, el cual asigna mayor peso a la clase minoritaria durante el entrenamiento.

Esta decisión metodológica responde a la finalidad pedagógica del sistema: priorizar la identificación de estudiantes con probabilidad de reprobación, aun cuando ello implique aceptar un número moderado de falsos positivos. El modelo no debe interpretarse como un instrumento de sanción, sino como una herramienta de apoyo para activar procesos de tutoría, refuerzo académico y acompañamiento personalizado.

**Sistemas de alerta temprana**

Los sistemas de alerta temprana integran modelos predictivos con procesos de intervención educativa. Su propósito no consiste en etiquetar definitivamente al estudiante, sino en generar señales tempranas que permitan activar tutorías, retroalimentación, planes de refuerzo o estrategias de aprendizaje personalizadas (Ouyang et al., 2023).

Ouyang et al. (2023) destacan que la integración de la analítica del aprendizaje con la predicción del rendimiento puede mejorar la toma de decisiones pedagógicas, siempre que los resultados del modelo se traduzcan en acciones concretas. En este sentido, la analítica predictiva debe complementarse con una analítica prescriptiva capaz de recomendar intervenciones específicas según el perfil de riesgo identificado.

La utilidad práctica de estos sistemas depende no solo de su desempeño estadístico, sino también de la interpretabilidad de las predicciones y de la aceptación por parte de los usuarios educativos (Sghir et al., 2023). Un modelo altamente preciso pero opaco puede generar desconfianza entre docentes y estudiantes, especialmente si las predicciones influyen en decisiones académicas relevantes.

Wang et al. (2023) propusieron un sistema integral de predicción del rendimiento académico que combina múltiples fuentes de información y técnicas de aprendizaje automático. Este tipo de arquitecturas evidencia la tendencia hacia soluciones más completas, que integran datos, modelos, visualización, explicabilidad y apoyo a la decisión. En el proyecto, esta integración se materializa mediante un flujo que incluye preparación de datos, análisis exploratorio, modelado supervisado, explicación de resultados y despliegue en una aplicación web interactiva.

**Inteligencia artificial explicable**

La incorporación de inteligencia artificial explicable (*Explainable Artificial Intelligence*, XAI) ha ganado relevancia en la predicción del rendimiento estudiantil. La explicabilidad resulta esencial cuando los modelos se utilizan para decisiones que afectan trayectorias educativas, pues permite identificar los factores que sustentan una predicción y facilitar la supervisión humana (Sghir et al., 2023).

Las técnicas como SHAP y LIME permiten estimar la contribución individual de las variables a una predicción específica. Estas metodologías complementan la importancia global de atributos generada por *Random Forest* y permiten explicar por qué un estudiante fue clasificado como de alto o bajo riesgo académico (Alalawi et al., 2023).

En el proyecto, la importancia de variables constituye un primer nivel de interpretabilidad. Los resultados evidencian que las calificaciones previas, las horas de estudio y el puntaje del examen son los factores con mayor influencia en la predicción. No obstante, la literatura recomienda complementar este análisis global con métodos locales de explicación, a fin de ofrecer explicaciones personalizadas para cada estudiante.

La transparencia algorítmica también contribuye a la confianza institucional. Cuando los docentes comprenden las razones detrás de una alerta, pueden contrastar la predicción con su conocimiento pedagógico y contextual del estudiante. De este modo, el modelo actúa como un apoyo decisional y no como un sustituto del criterio profesional docente (Ouyang et al., 2023).

**Consideraciones éticas**

La predicción del riesgo académico plantea desafíos éticos significativos. Entre ellos se encuentran la estigmatización de los estudiantes, el sesgo algorítmico, la falta de transparencia, la vulneración de la privacidad y el uso indebido de las predicciones para tomar decisiones punitivas (Romero & Ventura, 2020; Ouyang et al., 2023).

El sesgo puede surgir cuando los datos de entrenamiento reflejan desigualdades históricas o cuando ciertos grupos poblacionales están subrepresentados. En estos casos, el modelo puede reproducir o amplificar inequidades existentes, afectando de manera desproporcionada a estudiantes de contextos vulnerables (Rastrollo-Guerrero et al., 2020). Por ello, es necesario auditar los datos, revisar las variables utilizadas y evaluar el desempeño del modelo por subgrupos poblacionales.

La privacidad constituye otra preocupación central. Aunque el proyecto utiliza datos anonimizados de acceso abierto, la implementación en instituciones educativas reales requiere cumplir con principios de minimización de datos, consentimiento informado, seguridad de la información y limitación de la finalidad. Los datos sensibles no deben ser utilizados para clasificar, sancionar o excluir a los estudiantes (Romero & Ventura, 2020).

Desde una perspectiva pedagógica, las predicciones deben emplearse como insumos para la intervención formativa y no como instrumentos de clasificación definitiva. La supervisión docente, la contextualización de los resultados y la revisión periódica del sesgo son condiciones necesarias para un uso responsable de la inteligencia artificial en educación (Ouyang et al., 2023).

**Calidad de datos y reproducibilidad**

La calidad de los datos es determinante para la validez de los modelos de aprendizaje automático. La limpieza de valores faltantes, la eliminación de duplicados, la codificación de variables categóricas, la normalización y la prevención de fuga de datos (*data leakage*) son etapas críticas del pipeline de preparación (Albreiki et al., 2021).

La fuga de datos ocurre cuando información que no estaría disponible en el momento de la predicción se utiliza durante el entrenamiento del modelo. En el contexto educativo, esto puede suceder cuando se incluyen variables posteriores al periodo evaluativo, como calificaciones finales o resultados de exámenes definitivos, para predecir el riesgo antes de que estos ocurran (Alalawi et al., 2023).

La metodología CRISP-ML(Q) propone incorporar controles de calidad a lo largo de todo el ciclo de vida del modelo, desde la comprensión del negocio hasta el monitoreo posterior al despliegue (Studer et al., 2021). Esta metodología amplía el enfoque tradicional de CRISP-DM al incorporar explícitamente la aseguramiento de la calidad, la validación de datos, la verificación del modelo y el monitoreo operativo.

La disponibilidad de conjuntos de datos abiertos ha facilitado el desarrollo y la comparación de modelos predictivos. Kuzilek et al. (2017) presentaron el *Open University Learning Analytics Dataset*, un recurso ampliamente utilizado para investigar patrones de aprendizaje, desempeño y deserción en educación superior. Aunque el presente proyecto utiliza un conjunto de datos de Kaggle, la estructura metodológica es comparable: datos tabulares, variables de hábitos y rendimiento, preparación reproducible y evaluación mediante métricas de clasificación.

La reproducibilidad exige documentar el código, las versiones de las bibliotecas, los hiperparámetros, las particiones de datos y los procedimientos de validación. Estos elementos permiten que otros investigadores repliquen los resultados y evalúen la robustez del modelo en contextos distintos (Studer et al., 2021). En el proyecto, la utilización de un repositorio público, un cuaderno Jupyter y una aplicación desplegada en Streamlit favorece la trazabilidad y la verificabilidad de los resultados.

**Vacíos identificados**

La revisión de literatura evidencia que existen avances significativos en la predicción del rendimiento estudiantil mediante aprendizaje automático; sin embargo, persisten vacíos relacionados con la integración de modelos predictivos, explicabilidad y recomendaciones pedagógicas en interfaces accesibles para docentes (Sghir et al., 2023; Ouyang et al., 2023).

En primer lugar, muchos estudios se concentran en la comparación de algoritmos y métricas, pero menos frecuentemente articulan el modelo con un sistema de apoyo a la decisión que facilite intervenciones oportunas. En segundo lugar, la interpretabilidad suele limitarse a la importancia global de variables, sin incorporar explicaciones locales que permitan comprender el riesgo individual de cada estudiante (Alalawi et al., 2023).

En tercer lugar, persiste la necesidad de incorporar variables contextuales, socioeconómicas y territoriales que permitan comprender mejor las condiciones que influyen en el rendimiento académico. La omisión de estos factores puede reducir la validez externa de los modelos y limitar su capacidad para orientar políticas institucionales equitativas (Rastrollo-Guerrero et al., 2020).

Finalmente, la literatura evidencia la necesidad de diseñar sistemas que prioricen la supervisión humana, la protección de datos y el enfoque formativo. La inteligencia artificial no debe reemplazar el criterio docente, sino fortalecerlo mediante información oportuna, explicable y contextualizada (Ouyang et al., 2023).

**Aporte del proyecto**

El presente proyecto responde parcialmente a los vacíos identificados al desarrollar un prototipo de *Random Forest* con ponderación balanceada, análisis de importancia de variables y despliegue en una aplicación web interactiva. Su aporte consiste en transformar la predicción estadística en una herramienta de alerta temprana y acompañamiento pedagógico, manteniendo la supervisión humana como elemento central del proceso decisional.

La utilización de un modelo de ensamble como *Random Forest* permite aprovechar su capacidad para modelar relaciones no lineales, manejar interacciones entre variables y ofrecer medidas de importancia de atributos (Breiman, 2001). Asimismo, la aplicación de ponderaciones balanceadas responde a la necesidad de mejorar la detección de la clase minoritaria, correspondiente a estudiantes en riesgo de reprobación (Albreiki et al., 2021).

La integración de un flujo ETL, análisis exploratorio, modelado supervisado, explicación de resultados y despliegue web configura una arquitectura integral de inteligencia artificial aplicada a la educación. Esta arquitectura permite que docentes, tutores y coordinadores académicos accedan a predicciones, visualizaciones y recomendaciones pedagógicas de manera oportuna y comprensible (Wang et al., 2023).

## ANEXO 1: ENLACES A DATASETS REPRESENTATIVOS.

| Nombre del dataset | Descripción | Variables principales | Enlace |
|---|---|---|---|
| Student Performance Dataset | Conjunto de datos abierto con 5.000 registros para clasificacion del rendimiento estudiantil a partir de habitos de estudio y antecedentes. | Hours_Studied, Previous_Scores, Extracurricular_Activities, Sleep_Hours, Sample_Question_Papers_Practiced, Exam_Score, Performance_Index. | Kaggle: https://www.kaggle.com/datasets/suvidyasonawane/student-performance-dataset |

| | | | |
|---|---|---|---|
| Cuaderno Jupyter Reproducible | Project_ML_PRE.ipynb con flujo completo: EDA, YData Profiling, escalado, entrenamiento Random Forest y evaluacion. | Codigo Python 3.10 ejecutable, metricas validadas, matriz de confusion y curva ROC. | GitHub: https://github.com/Ambar1920/Project_ML_PRE |
| Aplicacion Web Streamlit | Prototipo interactivo en la nube con simulador en tiempo real y comparativa analitica de modelos. | EDA interactivo, metricas de clasificacion, simulador predictivo y recomendaciones prescriptivas. | Streamlit Cloud: https://Project_ML_PRE.streamlit.app |
| Landing Page Oficial | Portal web corporativo responsivo con diseno dark mode, navegador CRISP-ML(Q) y visor de ADRs. | Presentacion del proyecto, stack tecnologico, badges de herramientas y accesos directos. | GitHub Pages: https://Ambar1920.github.io/Project_ML_PRE/ |
| Video Interactivo BRAG | Presentacion ejecutiva de 1:15 minutos estructurada en 5 capitulos con locucion en espanol generada por IA. | Capitulos: El Problema, Los Datos, El Modelo, Resultados y La Aplicacion; controles de repeticion y loop. | Archivo: https://ambar1920.github.io/Project_ML_PRE/#video |
| Datos Abiertos Colombia - CSV recurso 3 | Otro archivo CSV público de Datos Abiertos Colombia. datos.gov | Depende del conjunto; útil para cruces contextuales y socioeconómicos. datos.gov | CSV descarga datos.gov |
| Oferta Programa Académico Colombia SNIES - Kaggle | Dataset de Kaggle con oferta académica colombiana basada en SNIES; sirve para exploración rápida y prototipos. kaggle | Código SNIES, programa, institución, nivel, modalidad, ubicación, periodo. kaggle | Kaggle - Oferta Programa Académico Colombia SNIES kaggle |
| Predict students' dropout and academic success - Kaggle | Dataset de educación superior para predecir deserción y éxito académico, útil como benchmark. kaggle | Factores sociales, económicos, académicos, rendimiento, etiqueta dropout/success. kaggle | Kaggle - Predict students' dropout and academic success kaggle |
| Kaggle - Datasets | Buscador general de datasets en Kaggle para educación y analítica predictiva. kaggle+1 | Miles de datasets con filtros por tema, formato y popularidad. kaggle+1 | Kaggle Datasets |